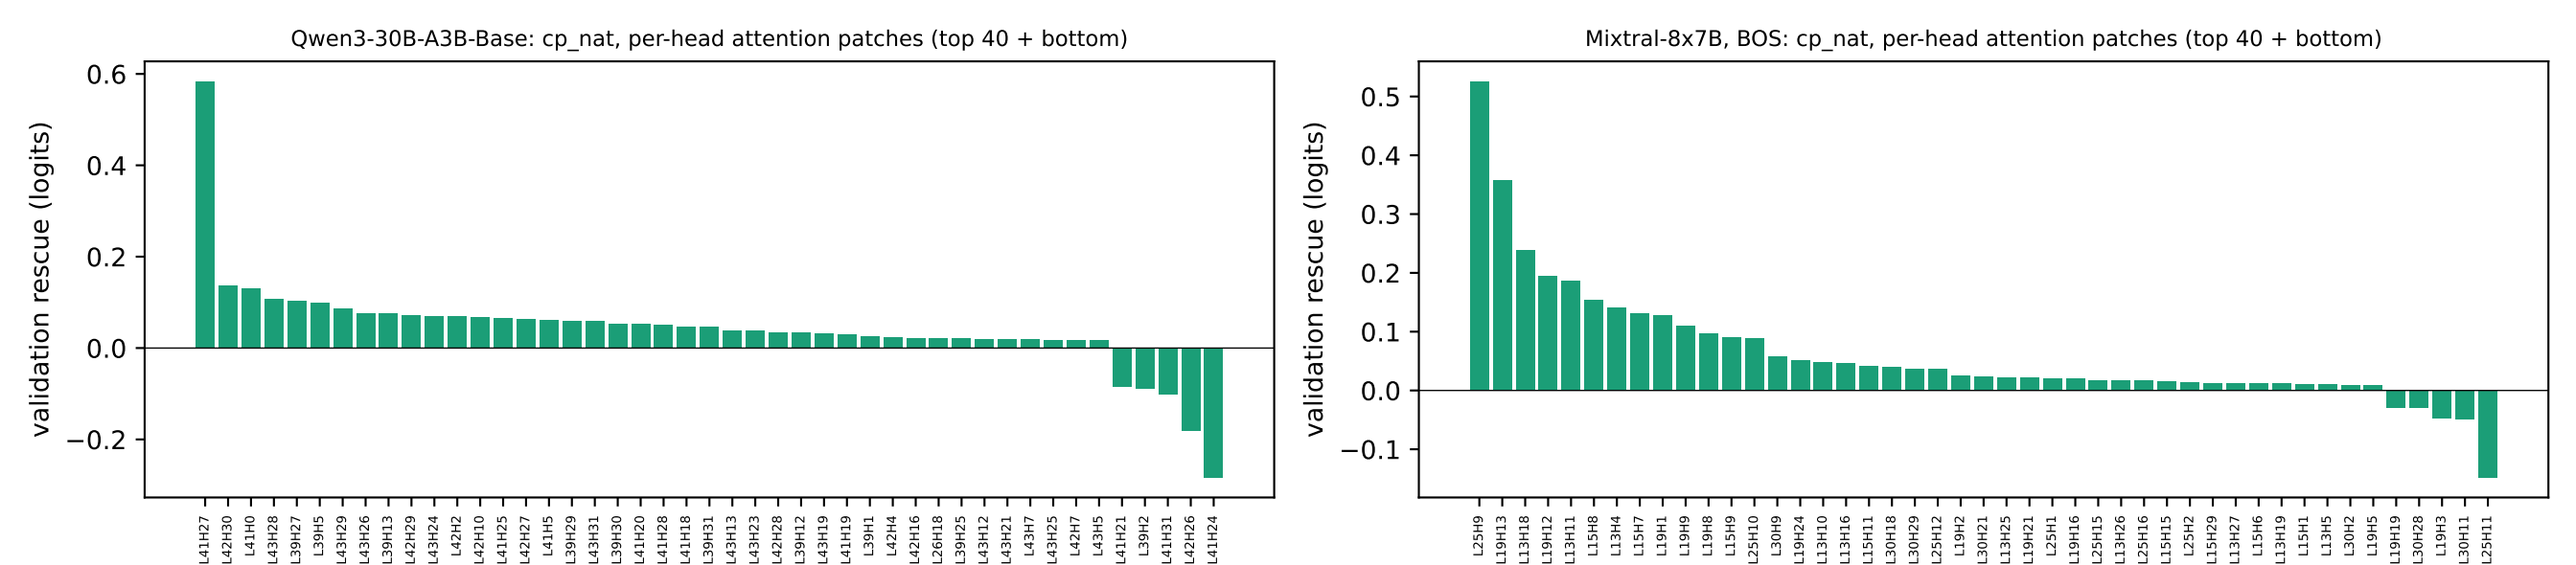
Qwen3-30B-A3B-Base: cp_nat, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.6
0.4
0.2
0.0
−0.2
L41H27 L42H30 L41H0 L43H28 L39H27 L39H5 L43H29 L43H26 L39H13 L42H29 L43H24 L42H2 L42H10 L41H25 L42H27 L41H5 L39H29 L43H31 L39H30 L41H20 L41H28 L41H18 L39H31 L43H13 L43H23 L42H28 L39H12 L43H19 L41H19 L39H1 L42H4 L42H16 L26H18 L39H25 L43H12 L43H21 L43H7 L43H25 L42H7 L43H5 L41H21 L39H2 L41H31 L42H26 L41H24
Mixtral-8x7B, BOS: cp_nat, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.5
0.4
0.3
0.2
0.1
0.0
−0.1
L25H9 L19H13 L13H18 L19H12 L13H11 L15H8 L13H4 L15H7 L19H1 L19H9 L19H8 L15H9 L25H10 L30H9 L19H24 L13H10 L13H16 L15H11 L30H18 L30H29 L25H12 L19H2 L30H21 L13H25 L19H21 L25H1 L19H16 L25H15 L13H26 L25H16 L15H15 L25H2 L15H29 L13H27 L15H6 L13H19 L15H1 L13H5 L30H2 L19H5 L19H19 L30H28 L19H3 L30H11 L25H11