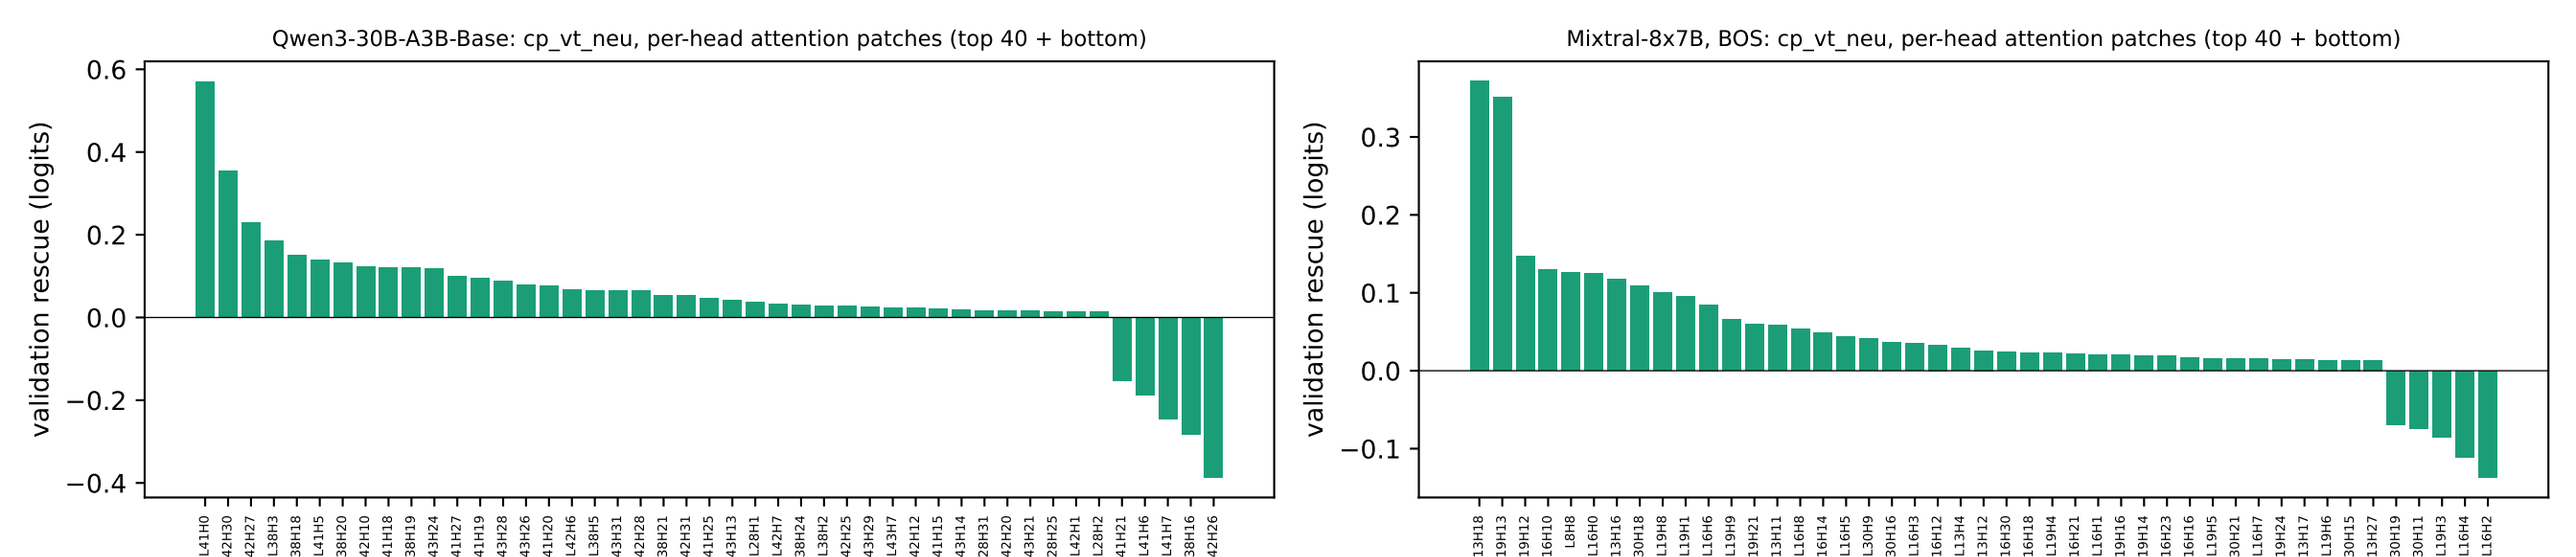
Qwen3-30B-A3B-Base: cp_vt_neu, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.6
0.4
0.2
0.0
−0.2
−0.4
L41H0
L42H30
L42H27
L38H3
L38H18
L41H5
L38H20
L42H10
L41H18
L38H19
L43H24
L41H27
L41H19
L43H28
L43H26
L41H20
L42H6
L38H5
L43H31
L42H28
L38H21
L42H31
L41H25
L43H13
L28H1
L42H7
L38H24
L38H2
L42H25
L43H29
L43H7
L42H12
L41H15
L43H14
L28H31
L42H20
L43H21
L28H25
L42H1
L28H2
L41H21
L41H6
L41H7
L38H16
L42H26
Mixtral-8x7B, BOS: cp_vt_neu, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.3
0.2
0.1
0.0
−0.1
L13H18
L19H13
L19H12
L16H10
L8H8
L16H0
L13H16
L30H18
L19H8
L19H1
L16H6
L19H9
L19H21
L13H11
L16H8
L16H14
L16H5
L30H9
L30H16
L16H3
L16H12
L13H4
L13H12
L16H30
L16H18
L19H4
L16H21
L16H1
L19H16
L19H14
L16H23
L16H16
L19H5
L30H21
L16H7
L19H24
L13H17
L19H6
L30H15
L13H27
L30H19
L30H11
L19H3
L16H4
L16H2