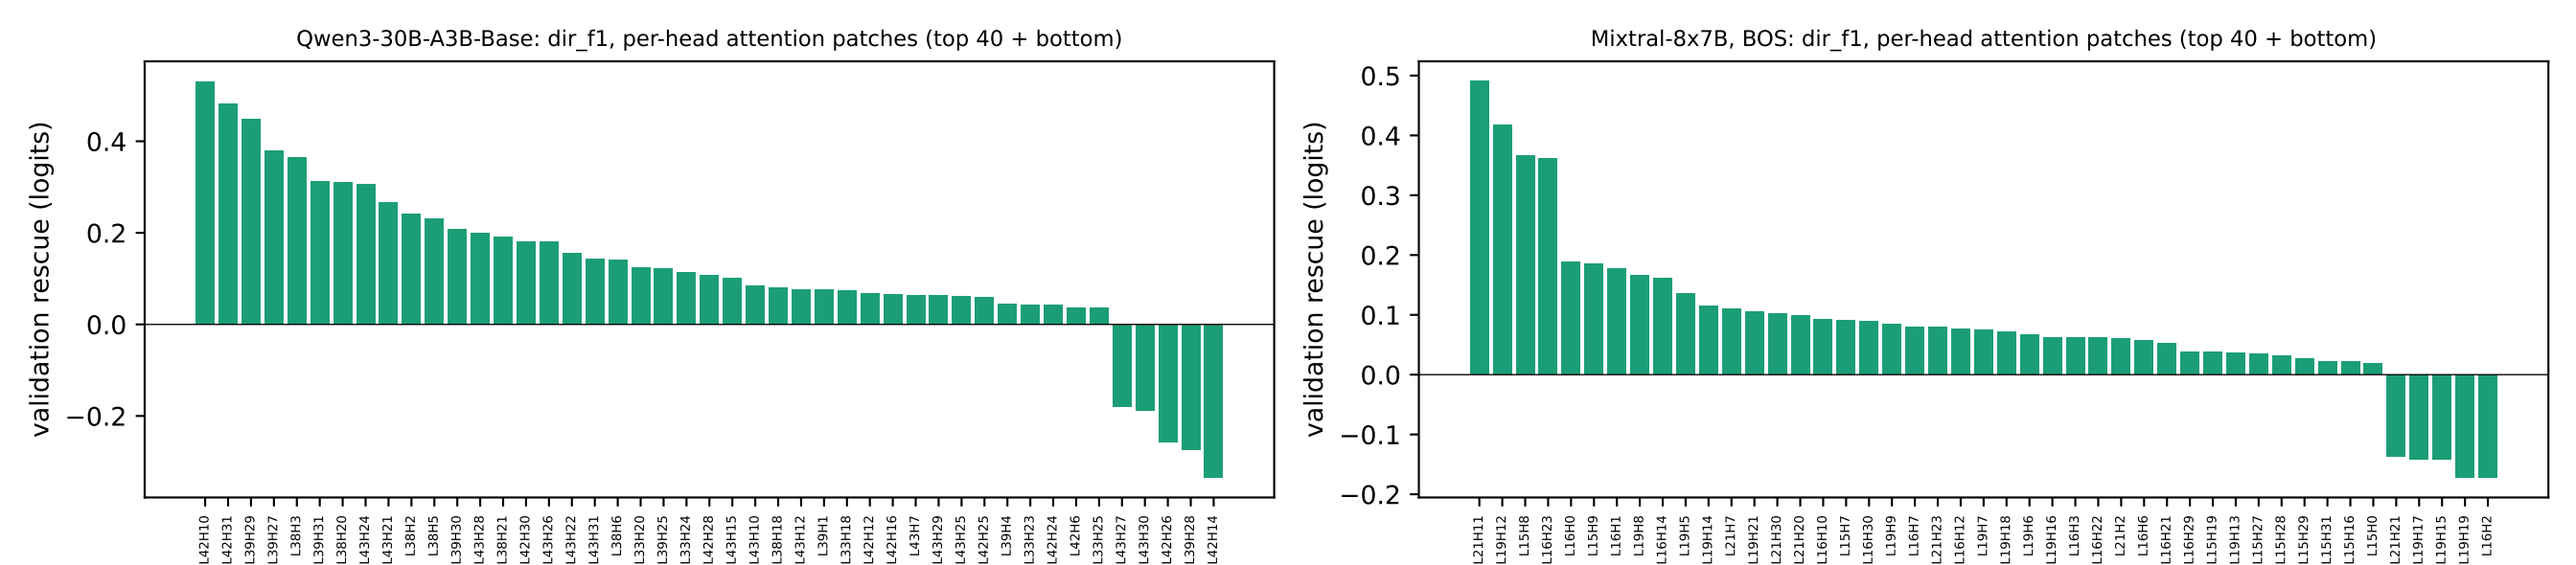
Qwen3-30B-A3B-Base: dir_f1, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.4
0.2
0.0
−0.2
L42H10 L42H31 L39H29 L39H27 L38H3 L39H31 L38H20 L43H24 L43H21 L38H2 L38H5 L39H30 L43H28 L38H21 L42H30 L43H26 L43H22 L43H31 L38H6 L33H20 L39H25 L33H24 L42H28 L43H15 L43H10 L38H18 L43H12 L39H1 L33H18 L42H12 L42H16 L43H7 L43H29 L43H25 L42H25 L39H4 L33H23 L42H24 L42H6 L33H25 L43H27 L43H30 L42H26 L39H28 L42H14
Mixtral-8x7B, BOS: dir_f1, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.5
0.4
0.3
0.2
0.1
0.0
−0.1
−0.2
L21H11 L19H12 L15H8 L16H23 L16H0 L15H9 L16H1 L19H8 L16H14 L19H5 L19H14 L21H7 L19H21 L21H30 L21H20 L16H10 L15H7 L16H30 L19H9 L16H7 L21H23 L16H12 L19H7 L19H18 L19H6 L19H16 L16H3 L16H22 L21H2 L16H6 L16H21 L16H29 L15H19 L19H13 L15H27 L15H28 L15H29 L15H31 L15H16 L15H0 L21H21 L19H17 L19H15 L19H19 L16H2