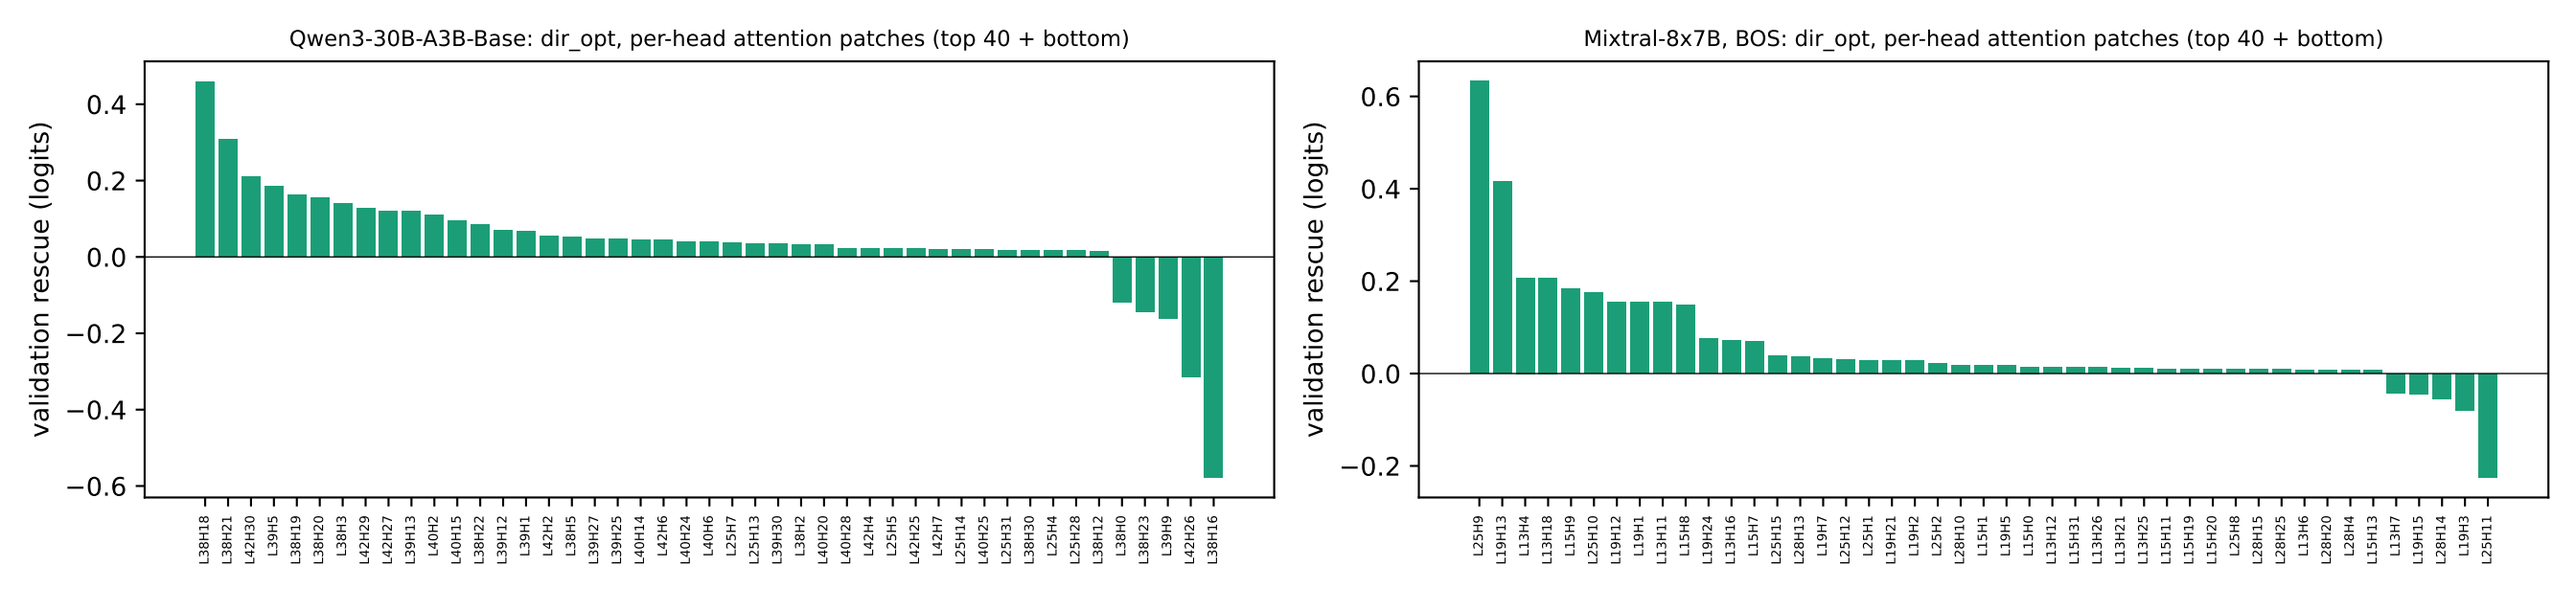
Qwen3-30B-A3B-Base: dir_opt, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.4
0.2
0.0
−0.2
−0.4
−0.6
L38H18
L38H21
L42H30
L39H5
L38H19
L38H20
L38H3
L42H29
L42H27
L39H13
L40H2
L40H15
L38H22
L39H12
L39H1
L42H2
L38H5
L39H27
L39H25
L40H14
L42H6
L40H24
L40H6
L25H7
L25H13
L39H30
L38H2
L40H20
L40H28
L42H4
L25H5
L42H25
L42H7
L25H14
L40H25
L25H31
L38H30
L25H4
L25H28
L38H12
L38H0
L38H23
L39H9
L42H26
L38H16
Mixtral-8x7B, BOS: dir_opt, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.6
0.4
0.2
0.0
−0.2
L25H9
L19H13
L13H4
L13H18
L15H9
L25H10
L19H12
L19H1
L13H11
L15H8
L19H24
L13H16
L15H7
L25H15
L28H13
L19H7
L25H12
L25H1
L19H21
L19H2
L25H2
L28H10
L15H1
L19H5
L15H0
L13H12
L15H31
L13H26
L13H21
L13H25
L15H11
L15H19
L15H20
L25H8
L28H15
L28H25
L13H6
L28H20
L28H4
L15H13
L13H7
L19H15
L28H14
L19H3
L25H11