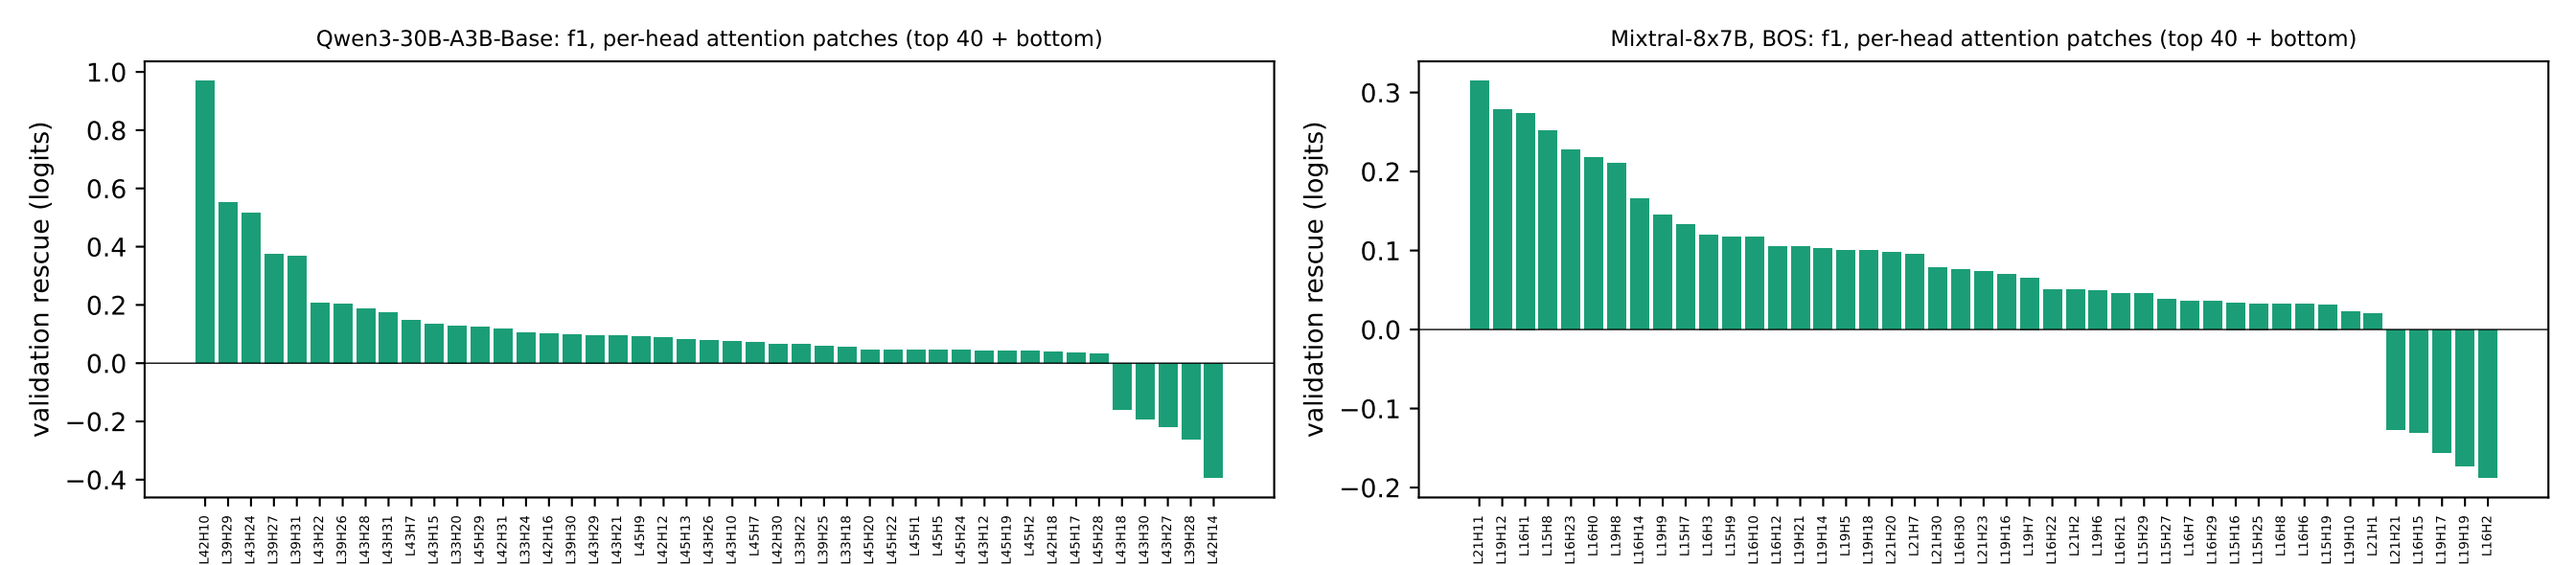
Qwen3-30B-A3B-Base: f1, per-head attention patches (top 40 + bottom)
validation rescue (logits)
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
L42H10
L39H29
L43H24
L39H27
L39H31
L43H22
L39H26
L43H28
L43H31
L43H7
L43H15
L33H20
L45H29
L42H31
L33H24
L42H16
L39H30
L43H29
L43H21
L45H9
L42H12
L45H13
L43H26
L43H10
L45H7
L42H30
L33H22
L39H25
L33H18
L45H20
L45H22
L45H1
L45H5
L45H24
L43H12
L45H19
L45H2
L42H18
L45H17
L45H28
L43H18
L43H30
L43H27
L39H28
L42H14
Mixtral-8x7B, BOS: f1, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.3
0.2
0.1
0.0
−0.1
−0.2
L21H11
L19H12
L16H1
L15H8
L16H23
L16H0
L19H8
L16H14
L19H9
L15H7
L16H3
L15H9
L16H10
L16H12
L19H21
L19H14
L19H5
L19H18
L21H20
L21H7
L21H30
L16H30
L21H23
L19H16
L19H7
L16H22
L21H2
L19H6
L16H21
L15H29
L15H27
L16H7
L16H29
L15H16
L15H25
L16H8
L16H6
L15H19
L19H10
L21H1
L21H21
L16H15
L19H17
L19H19
L16H2