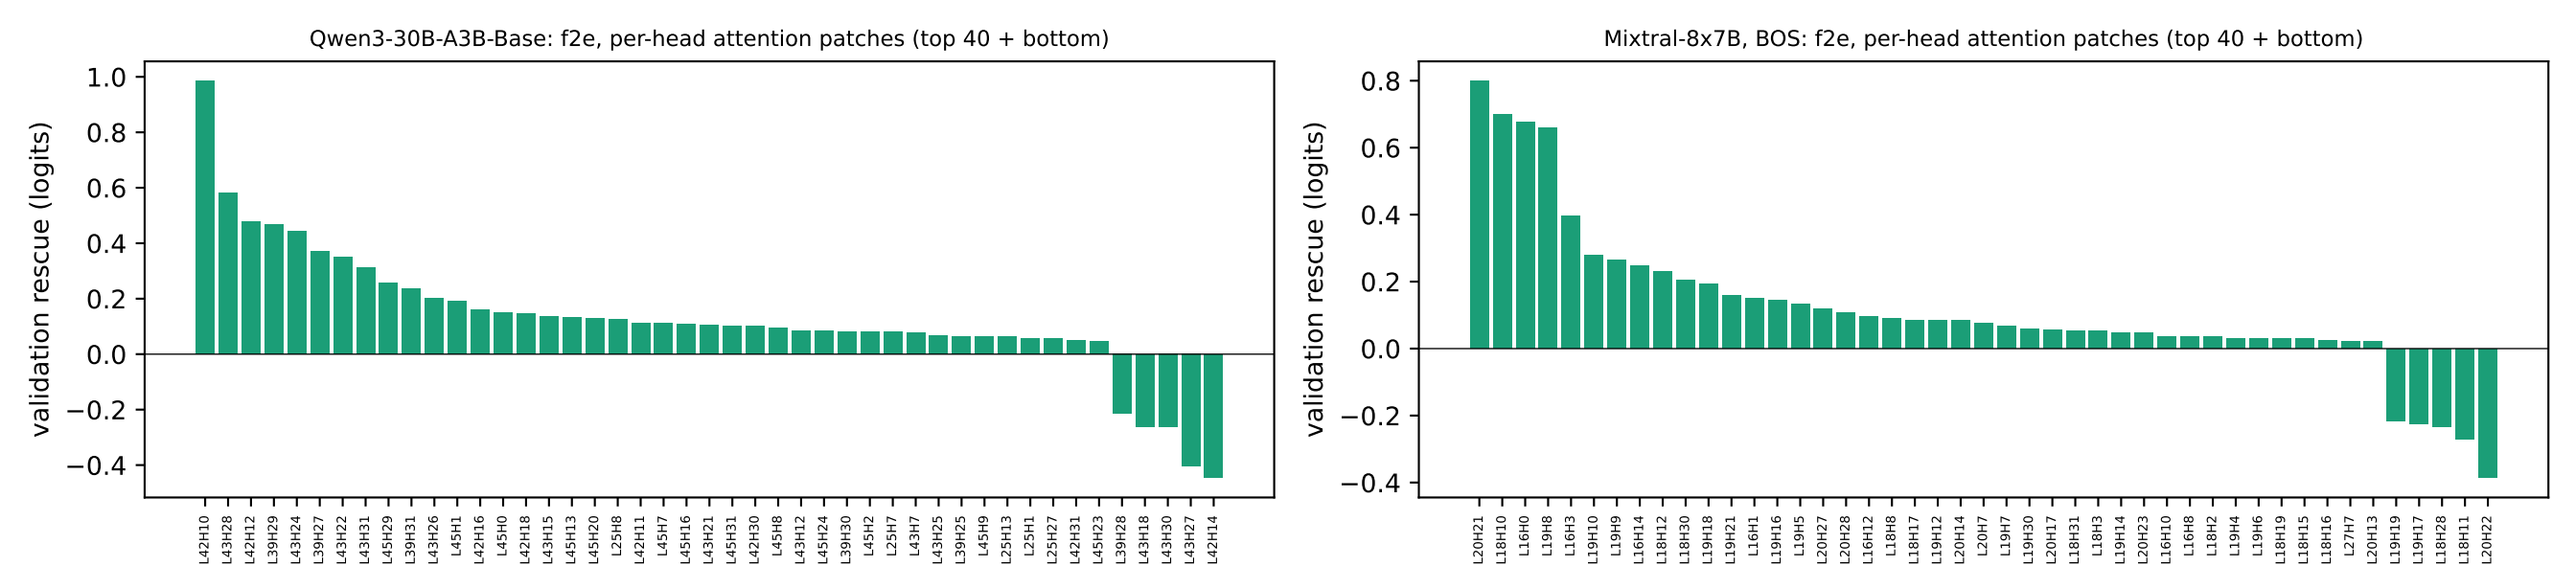
Qwen3-30B-A3B-Base: f2e, per-head attention patches (top 40 + bottom)
validation rescue (logits)
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
L42H10
L43H28
L42H12
L39H29
L43H24
L39H27
L43H22
L43H31
L45H29
L39H31
L43H26
L45H1
L42H16
L45H0
L42H18
L43H15
L45H13
L45H20
L25H8
L42H11
L45H7
L45H16
L43H21
L45H31
L42H30
L45H8
L43H12
L45H24
L39H30
L45H2
L25H7
L43H7
L43H25
L39H25
L45H9
L25H13
L25H1
L25H27
L42H31
L45H23
L39H28
L43H18
L43H30
L43H27
L42H14
Mixtral-8x7B, BOS: f2e, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
L20H21
L18H10
L16H0
L19H8
L16H3
L19H10
L19H9
L16H14
L18H12
L18H30
L19H18
L19H21
L16H1
L19H16
L19H5
L20H27
L20H28
L16H12
L18H8
L18H17
L19H12
L20H14
L20H7
L19H7
L19H30
L20H17
L18H31
L18H3
L19H14
L20H23
L16H10
L16H8
L18H2
L19H4
L19H6
L18H19
L18H15
L18H16
L27H7
L20H13
L19H19
L19H17
L18H28
L18H11
L20H22