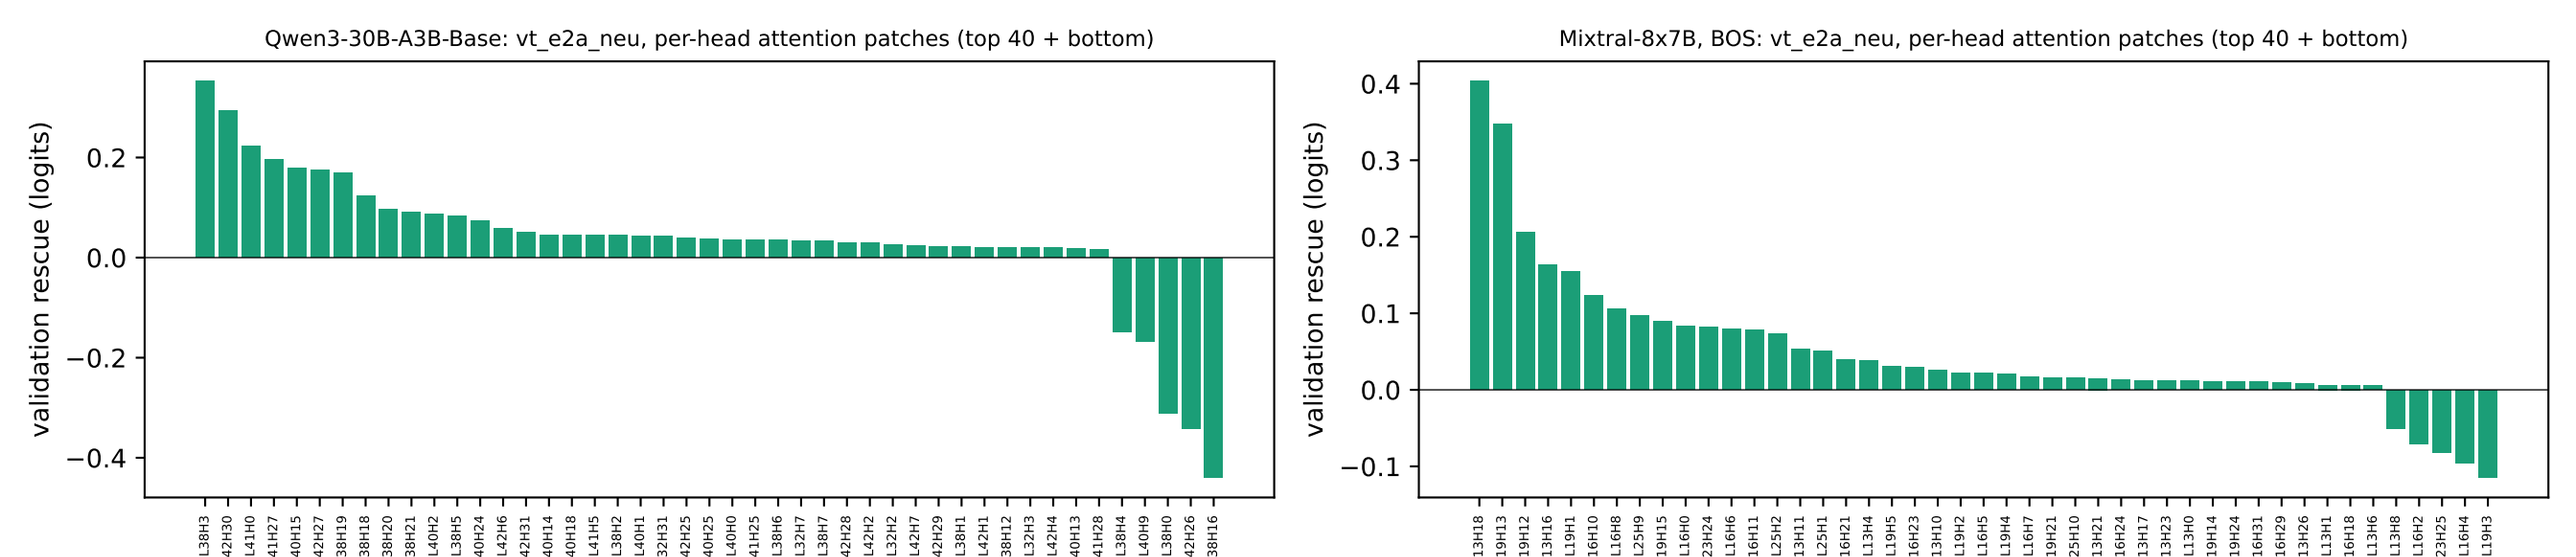
Qwen3-30B-A3B-Base: vt_e2a_neu, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.2
0.0
−0.2
−0.4
L38H3
L42H30
L41H0
L41H27
L40H15
L42H27
L38H19
L38H18
L38H20
L38H21
L40H2
L38H5
L40H24
L42H6
L42H31
L40H14
L40H18
L41H5
L38H2
L40H1
L32H31
L42H25
L40H25
L40H0
L41H25
L38H6
L32H7
L38H7
L42H28
L42H2
L32H2
L42H7
L42H29
L38H1
L42H1
L38H12
L32H3
L42H4
L40H13
L41H28
L38H4
L40H9
L38H0
L42H26
L38H16
Mixtral-8x7B, BOS: vt_e2a_neu, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.4
0.3
0.2
0.1
0.0
−0.1
L13H18
L19H13
L19H12
L13H16
L19H1
L16H10
L16H8
L25H9
L19H15
L16H0
L23H24
L16H6
L16H11
L25H2
L13H11
L25H1
L16H21
L13H4
L19H5
L16H23
L13H10
L19H2
L16H5
L19H4
L16H7
L19H21
L25H10
L13H21
L16H24
L13H17
L13H23
L13H0
L19H14
L19H24
L16H31
L16H29
L13H26
L13H1
L16H18
L13H6
L13H8
L16H2
L23H25
L16H4
L19H3