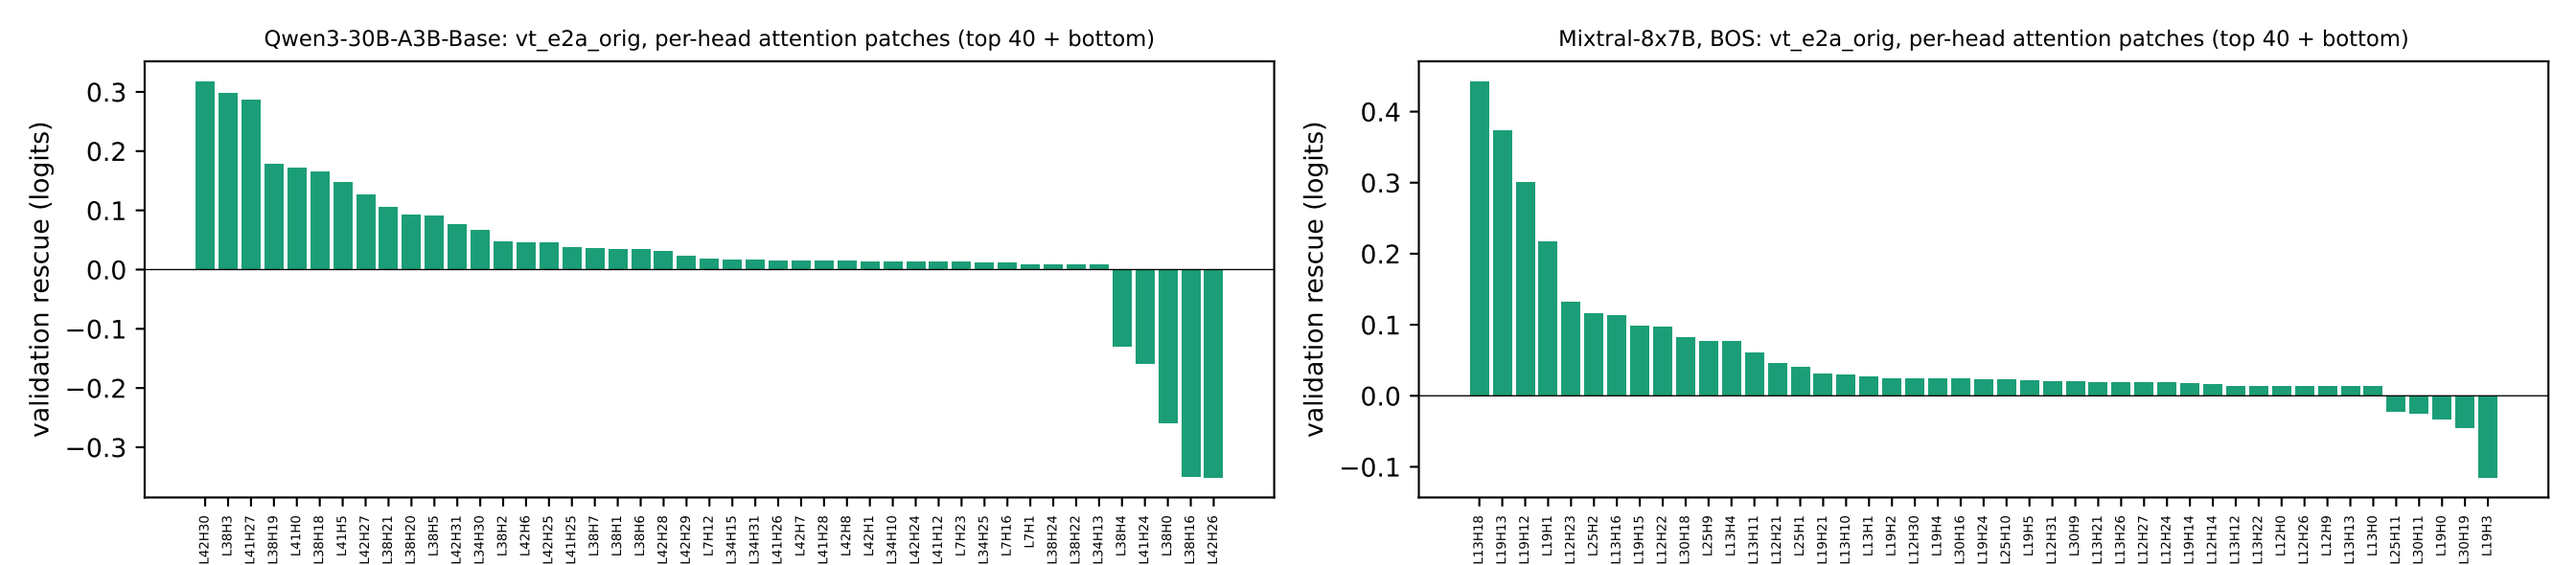
Qwen3-30B-A3B-Base: vt_e2a_orig, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.3
0.2
0.1
0.0
−0.1
−0.2
−0.3
L42H30
L38H3
L41H27
L38H19
L41H0
L38H18
L41H5
L42H27
L38H21
L38H20
L38H5
L42H31
L34H30
L38H2
L42H6
L42H25
L41H25
L38H7
L38H1
L38H6
L42H28
L42H29
L7H12
L34H15
L34H31
L41H26
L42H7
L41H28
L42H8
L42H1
L34H10
L42H24
L41H12
L7H23
L34H25
L7H16
L7H1
L38H24
L38H22
L34H13
L38H4
L41H24
L38H0
L38H16
L42H26
Mixtral-8x7B, BOS: vt_e2a_orig, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.4
0.3
0.2
0.1
0.0
−0.1
L13H18
L19H13
L19H12
L19H1
L12H23
L25H2
L13H16
L19H15
L12H22
L30H18
L25H9
L13H4
L13H11
L12H21
L25H1
L19H21
L13H10
L13H1
L19H2
L12H30
L19H4
L30H16
L19H24
L25H10
L19H5
L12H31
L30H9
L13H21
L13H26
L12H27
L12H24
L19H14
L12H14
L13H12
L13H22
L12H0
L12H26
L12H9
L13H13
L13H0
L25H11
L30H11
L19H0
L30H19
L19H3