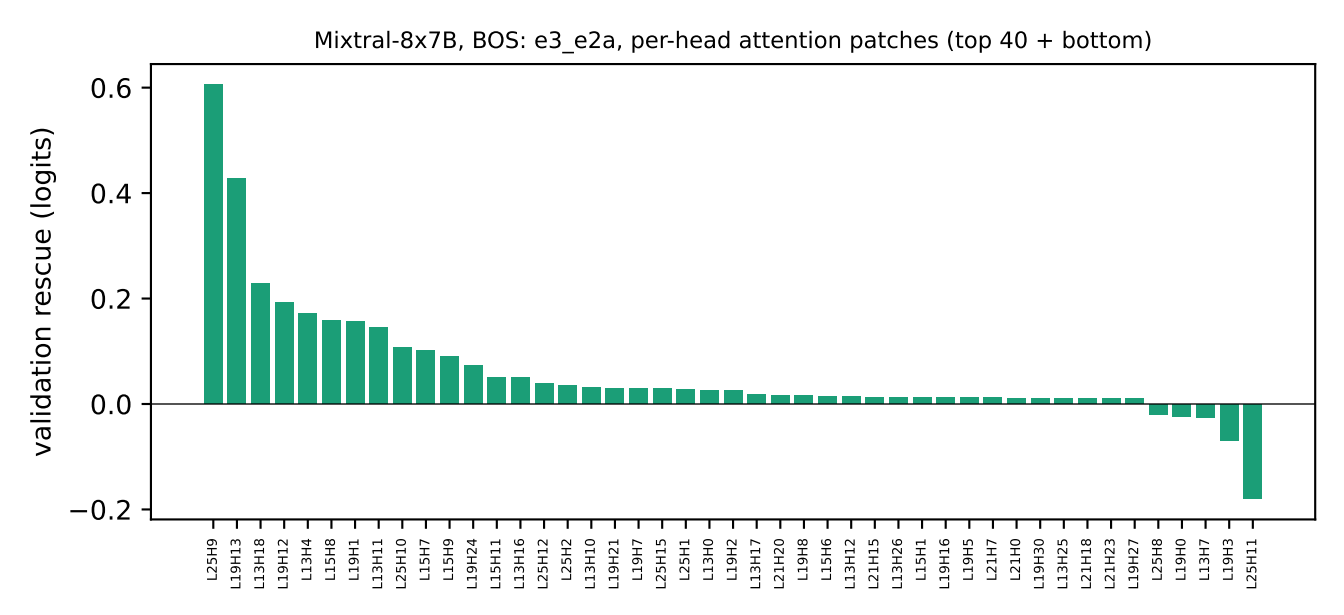
Mixtral-8x7B, BOS: e3_e2a, per-head attention patches (top 40 + bottom)
validation rescue (logits)
0.6
0.4
0.2
0.0
−0.2
L25H9
L19H13
L13H18
L19H12
L13H4
L15H8
L19H1
L13H11
L25H10
L15H7
L15H9
L19H24
L15H11
L13H16
L25H12
L25H2
L13H10
L19H21
L19H7
L25H15
L25H1
L13H0
L19H2
L13H17
L21H20
L19H8
L15H6
L13H12
L21H15
L13H26
L15H1
L19H16
L19H5
L21H7
L21H0
L19H30
L13H25
L21H18
L21H23
L19H27
L25H8
L19H0
L13H7
L19H3
L25H11